TEKNOFEST
HAVACILIK, UZAY VE TEKNOLOJİ FESTİVALİ

SAĞLIKTA YAPAY ZEKA YARIŞMASI
KRİTİK TASARIM RAPORU

TAKIM ADI

ChatGPTree

BAŞVURU ID

3321623

İÇİNDEKİLER

1. TAKIM ŞEMASI 3

2. PROBLEME EN YAKIN ÇÖZÜM SUNAN ULUSLARARASI MAKALELERİN ÖZETİ 3

2.1. Sağlıkta Yapay Zeka 3

2.2. Seçilen algoritmaların karşılaştırılması 4

2.3. Görüntü Ön İşleme 4

3. KULLANILAN VERİ SETİ VE ALGORİTMALAR 4

3.1. Veri Kümesi 4

3.2. Kullanılan Algoritma 5

3.3. ResUNet++ 5

4. SONUÇLAR VE İNCELEME 6

5. ÖZGÜNLÜK 7

REFERANSLAR 9

TEKNOFEST
HAVACILIK, UZAY VE TEKNOLOJİ FESTİVALİ

1. TAKIM ŞEMASI

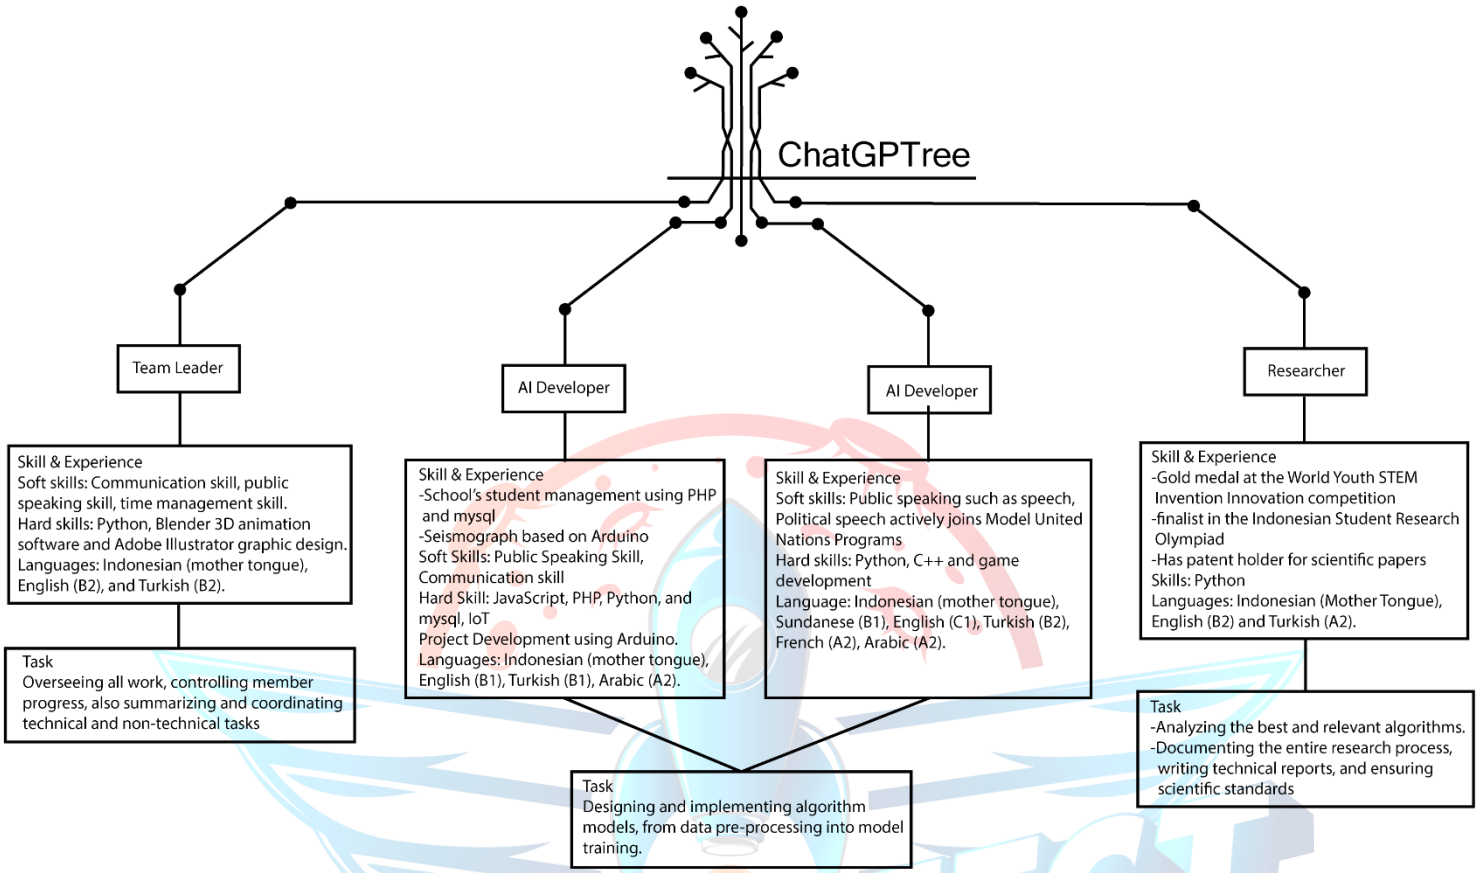


Figure 1. *Team Chart*

2. PROBLEME EN YAKIN ÇÖZÜM SUNAN ULUSLARARASI MAKALELERİN ÖZETİ

2.1. Sağlıkta Yapay Zeka

Günümüzde yapay zekâ, insan zekâsını temsil etme yeteneğine sahiptir; böylece yapay zekâ yükleri azaltabilir, geleneksel metodolojilerin yerini alabilir ve hatta sağlık da dâhil olmak üzere birçok alanda dönüştürücü bir potansiyele öncülük edebilir. Daha iyi performans elde etmek için, makine öğrenimi ve derin öğrenmedeki gelişmelere bağlı olarak farklı problemleri çözmek ve karar vermek için çeşitli algoritmalar ortaya çıkmaktadır. (Wang & Preininger, 2019). Yapay zekanın sağlık alanındaki önemli sorumluluklarından biri, yapay zekanın doku üzerindeki anormallikleri tespit etmeyi amaçladığı bilgisayarla görme görevidir.

Genel olarak, farklı algoritmalar farklı çıktılarla sonuçlanır ve bu alandaki zorluklardan biri de özel tıbbi görüntüleme mimarilerinin eksikliğidir (Rajpurkar, Chen, Banerjee, & Topol, 2022). Bu nedenle, bu raporda "İstediğimiz hedeflere ulaşmak için hangi algoritmayı uygulayacağız ve neden bu modeli seçiyoruz?" sorusunu çözmek için farklı algoritmaları karşılaştırarak araştırma ve deneylerimizi aktarmak istiyoruz.

2.2. Seçilen algoritmaların karşılaştırılması

Tabel 1. Comparison of the chosen algorithms

Algorithms	Datasets	IoU (%)
U-Net (Ronneberger, Fischer, & Brox, 2015)	PhC-U373	92.0
	DiC-HeLa	77.6
GAN-Based Models (Xue, Xu, Zhang, Long, & Huang, 2018)	BRATS 2015 Test	79.9
	BRATS 2013 Leaderboard	72.4
TransFuse (Zhang, Liu, & Hu, 2021)	Kvasir	86.3
	CVC-ClinicDB	86.8
Mask R-CNN (with ResNet50) (Qadir, et al., 2019)	CVC-ClinicDB	63.9
Deeplab v3+ (Chen, Zhu, Papandreou, Schroff, & Adam, 2018)	PASCAL VOC 2012	89.0
	Cityscapes	82.1

Birinci tabloda, biyomedikal görüntü segmentasyonunu uygulamak için algoritmaların karşılaştırma hassasiyetidir. Önceki dergiye dayanarak, U-Net diğerlerinden daha yeteneklidir; bu nedenle, bu modelle ilgili araştırma yapmaya başlıyoruz çünkü U-Net, görüntü segmentasyonu ile ilgili görevleri çözmek için standart mimari olmuştur. Modelin çıktısının veri kümesine bağlı olduğunu vurgulamak çok önemlidir.

2.3. Görüntü Ön İşleme

Veri artırma işlem hattı, model sağlamlığını ve genelleştirmeyi artırmak için geometrik dönüşümleri (yatay/dikey çevirmeler, döndürmeler, elastik/grid/optik deformasyonlar), fotometrik ayarlamaları (parlaklık/kontrast, ton/doygunluk kaymaları, CLAHE, gama düzeltmesi) ve düzenleme tekniklerini (CoarseDropout, RandomResizedCrop) birleştirir (Shorten & Khoshgoftaar, 2019). Görüntü normalizasyonu için, daha doğru eğitim verimliliği için veri kümesi görüntülerine dayalı ortalama ve standart sapma değerini hesaplıyoruz (Tellez, et al., 2019). Boru hattı, klinik ve geometrik değişkenlikte model performansını iyileştirmek için gerçekçilik ve çeşitliliği dengeler.

3. KULLANILAN VERİ SETİ VE ALGORİTMALAR

3.1. Veri Kümesi

Bu çalışmada, modelin genelleştirilmesini doğrulamak için iki veri kümesi kullandık. Veri kümesi bölünmesinde (Refaeilzadeh, Tang, & Liu, 2009) çalışmasına atıfta bulunarak, %80 eğitim verisi ve %20 doğrulama verisi bölünmesinin, aşırı uyum olmadan performans değerlendirmesi için yeterli veriyi korurken modelin eğitim ihtiyaçlarını dengelemek için en uygun olduğunu kanıtlayan 80:20 oranını uyguladık.

Algoritma modelinin eğitiminde ana veri kümesi olarak CVC-ClinicDB'yi kullanıyoruz. CVC-ClinicDB, endoskopistler tarafından elle bölütlenmiş 612 yüksek çözünürlüklü görüntüden (384×288 piksel) oluşan bir kolonoskopi polip bölütleme kıyaslama veri kümesidir (Bernal, et al., 2015).

3.2. Kullanılan Algoritma

Daha önce de belirtildiği üzere, U-Net yüzdesi en yüksek olduğu için bu çalışmada U-Net kullanmaya karar verdik. Bununla birlikte, U-Net'in kendisi çeşitli türlere ayrılmıştır. Kodlayıcı olarak ResNet'i seçtik çünkü ResNet küçük veriler (<1,000) için en iyi kodlayıcıdır (Jha, et al., 2019). Ayrıca EfficientNetB4, AttentionNet ve ResNet gibi birkaç U-Net kodlayıcısını deneyimiz olarak eğitiyoruz.

3.3. ResUNet++

ResUNet++, iki klasik CNN algoritması olan U-Net ve ResNet'in mimarisini benimser. U-Net, biyomedikal görüntü segmentasyonu için inanılmaz bir algoritmadır ve köprü olarak darboğaz ile kodlayıcı ve kod çözücü için iki koldan oluşur, bu model ayrıca uzamsal ayrıntıları korumak için atlama bağlantıları uygular. ResNet'in mimaride rol almasıyla, daha derin bir sinir ağının bozulma problemini çözmesine, performansı artırmasına ve aynı zamanda hesaplama maliyetini düşürmesine izin verebilir.

ResUNet++ mimarisi üç genişletilmiş mimariye daha sahiptir: sıkma ve uyarma ağı, Atrous Spatial Pyramid Pooling (ASPP) ve dikkat birimleri. Her renk her resim için eşit derecede kullanışlı değildir; bu nedenle, sıkma ve uyarma (SE) birimi hangi "renklerin" (veya kanalın) en önemli olduğuna karar vermek ve odaklanmak için rol alır. Böylece, görüntü segmentasyonu alanında ağın daha iyi performans göstermesini sağlayabilir.

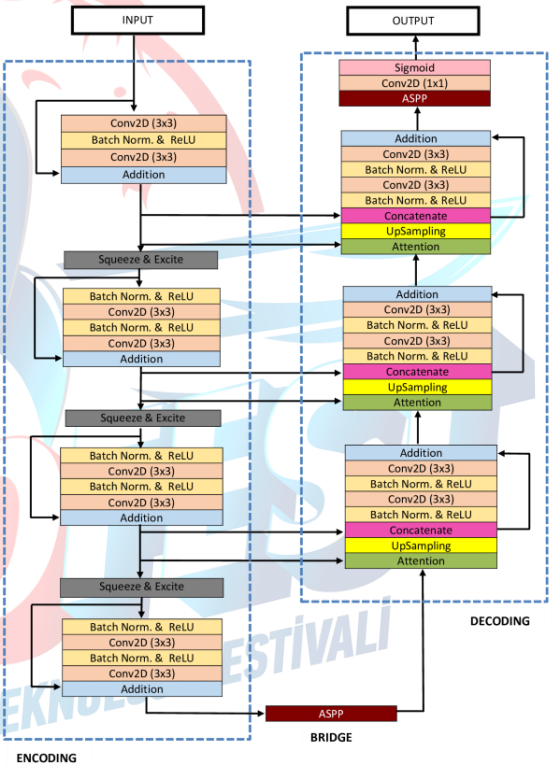


Figure 2. *Architecture ResUNet++*

ASPP mekanizması, aynı resme bakmak için farklı yakınlaştırma seviyelerine sahip bir kamera gibidir ve bu da ağın resmin ayrıntılarını görmesini sağlar. "Atrous" veya genişletilmiş konvolüsyon filtreye 'delikler' ekler, bu da filtrenin bazı pikselleri atladığı anlamına gelir. Bir filtre ayrıntıları yakalamak için küçük bir boşluğa (yakınlaştırılmış) veya daha büyük resmi yakalamak için daha büyük

bir boşluğa (uzaklaştırılmış) sahip olabilir. Bu, ağın görüntüyü yeniden boyutlandırmadan veya kırpmadan hem küçük hem de büyük nesneleri algılaması ve nesneyi boyutundan bağımsız olarak tanıması için kullanışlıdır.

Dikkat birimi, ağın görüntünün hangi kısımlarına daha fazla dikkat etmesi gerektiğine karar vermesine yardımcı olur. Ağ, önemli görünen özellikleri değerlendirerek ve bunlara daha fazla ağırlık vererek daha iyi tahmin yapabilir. Örneğin, ağ sadece poliplerin kendisine odaklanabilir ve arka planı ihmal edebilir. Bu nedenle model görüntünün en alakalı kısımlarına odaklanabilir (Jha, ve diğerleri, 2019).

4. SONUÇLAR VE İNCELEME

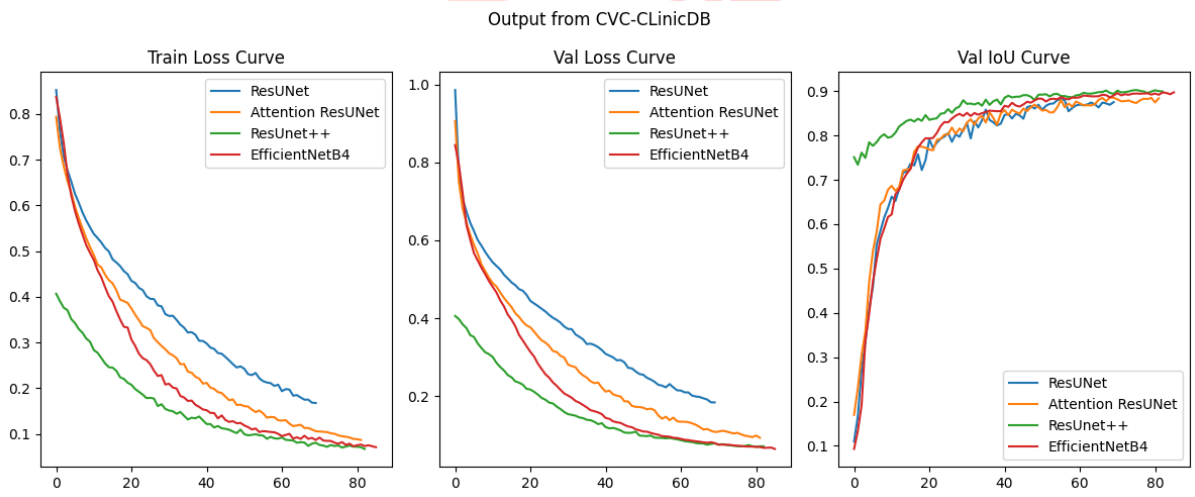


Figure 3. *Output from CVC-ClinicDB dataset*

Sunulan sonuçlar dört modelin eğitim kaybı, doğrulama kaybı ve doğrulama Birlik üzerinden Kesişim (IoU) performansını karşılaştırmaktadır. ResU-Net en yüksek eğitim kaybını, doğrulama kaybını ve en düşük doğrulama IoU'sunu göstererek temel performansa işaret etmektedir. AttentionU-Net, daha düşük eğitim kaybı, doğrulama kaybı ve %88,40'lık biraz daha yüksek IoU ile önemli ölçüde iyileşir. ResU-Net++ daha da iyi sonuçlar elde ederek eğitim ve doğrulama kayıplarını daha da azaltır ve %90,27 ile en yüksek doğrulama IoU'suna ulaşarak üstün segmentasyon doğruluğuna işaret eder. EfficientNetB4, en düşük eğitim ve doğrulama kayıplarını elde ederken, ResU-Net++ ile karşılaştırıldığında marjinal olarak daha düşük bir IoU'ya sahiptir. Bu, ResU-Net++'ın, EfficientNetB4'ün daha güçlü kayıp minimizasyonuna rağmen, muhtemelen bağlamsal ayrıntıları yakalamadaki mimari avantajları nedeniyle segmentasyon görevleri için daha iyi genelleme yaptığı anlamına gelir. Genel olarak, ResU-Net++ kayıp azaltma ve segmentasyon performansı arasında en iyi dengeyi kurmaktadır.

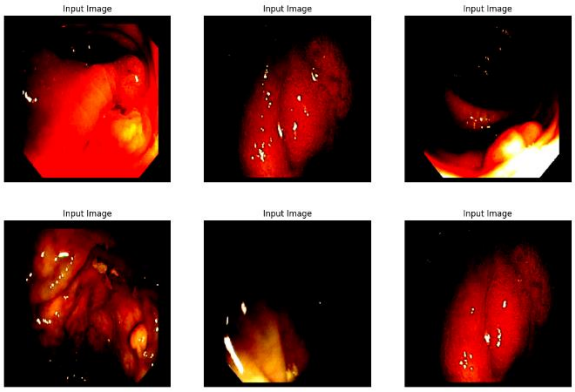


Figure 4. *Input image*

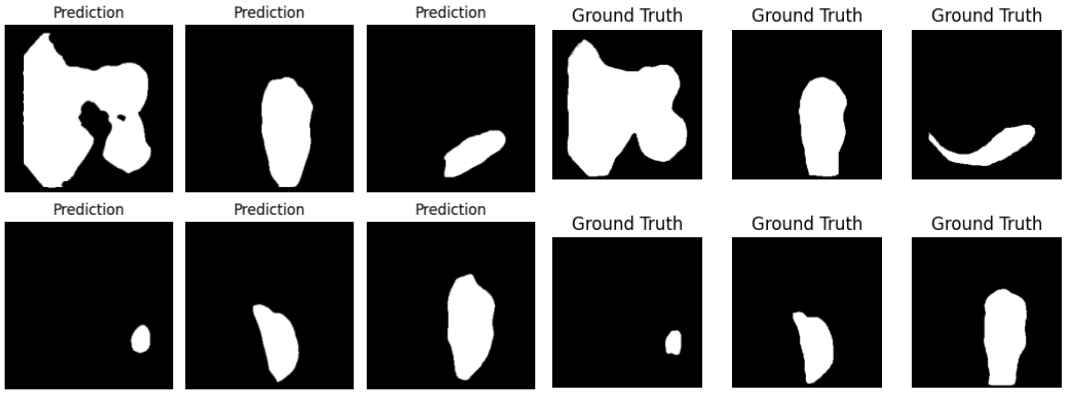


Figure 5. *Prediction & Ground Trurth*

Şekil 4 ve 5'te giriş görüntüleri, temel gerçek ve elde ettiğimiz tahminler gösterilmektedir. Giriş görüntüleri normalize edilmiş ve veri artırma işleminden geçirilmiştir.

5. ÖZGÜNLÜK

Eğitim sürecini hızlandırmak için projemizi, her ikisi de GPU tabanlı kodlama ortamları sağlayan Google Colab ve Kaggle kullanarak uyguluyoruz. Bu platformlar, manuel kurulum ihtiyacını ortadan kaldıran çok çeşitli makine öğrenimi kütüphaneleri ile önceden donatılmıştır. Projemiz için PyTorch, NumPy, OpenCV ve Albumentations kullanarak hem donanım hem de yazılım gereksinimlerimizin karşılanmasını sağlıyoruz.

Modeli verilerimizle beslemeden önce, veri kümesinin kalitesini artırmak için veri artırma ve normalleştirme uygulayarak veri kümesini önceden işledik. Böylece, bunlar algoritmanın öğrenme sürecini etkileyebilir.

Tabel 2. Hyperparameters tuned value

Hyperparameters	value
Batch size	16
learning rate	5e-5
weight decay	1e-4

Seçtiğimiz tüm CNN algoritmaları arasından, klasik vanilya U-Net mimarisinin biyomedikal görüntü segmentasyon görevlerini çözmede en iyi performansı elde ettiğini gördük. Bu nedenle, en iyi sonucu elde etmek için modelimizi geliştirmek üzere U-Net, kodlayıcı varyasyonları ve hiperparametre ayarlama ile ilgili araştırmalarımıza başladık. Sonuç olarak, temel olarak U-Net, kodlayıcı olarak ResNet ve en son teknolojiye sahip sonuçlara ulaşmak için üç genişletilmiş mimarimiz daha var. Bunlar birlikte ResUNet++'ın nihai tasarımına benzemektedir.

TEKNOFEST
HAVACILIK, UZAY VE TEKNOLOJİ FESTİVALİ

REFERANSLAR

Bernal, J., Sánchez, J., Fernández-Esparrach, G., Gil, D., Rodríguez, C., & Vilarino, F. (2015). WM-DOVA Maps for Accurate Polyp Highlighting in Colonoscopy Videos. *Computerized Medical Imaging and Graphics Vol. 43*, 99-111.

Chen, L. C., Zhu, Y., Papandreou, G., Schroff, F., & Adam, H. (2018). Encoder-Decoder with Atrous Separable Convolution for Semantic Image Segmentation. *European Conference on Computer Vision* , 801-818.

Jha, D., Smedsrud, P., Riegler, M., Johansen, D., Lange, T. d., Halvorsen, P., & Johansen, H. (2019). ResUNet++: An Advanced Architecture for Medical. *IEEE International Symposium on Multimedia*, 225-230.

Qadir, H. A., Shin, Y., Solhusvik, J., Bergsland, J., Aabakken, L., & Balasingham, I. (2019). Polyp Detection and Segmentation using Mask R-CNN: Does a Deeper Feature Extractor CNN Always Perform Better? *13th International Symposium on Medical Information and Communication Technology*, 1-6.

Rajpurkar, P., Chen, E., Banerjee, O., & Topol, E. (2022). AI in health and medicine. *Nature Medicine Vol. 28*, 31-38.

Refaeilzadeh, P., Tang, L., & Liu, H. (2009). Cross-Validation. *Encyclopedia of Database Systems (Springer)*, 532-538.

Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional Networks for Biomedical. *Computer Science Department and BIOSS Centre for Biological Signalling Studies,*, 234-241.

Shorten, C., & Khoshgoftaar, T. (2019). A survey on Image Data Augmentation for Deep Learning. *Journal of Big Data*, 1-48.

Tellez, D., Litjens, G., Bándi, P., Bulten, W., Bokhorst, J. -M., Ciompi, F., & Laak, J. v. (2019). Quantifying the Effects of Data Augmentation and Stain Color Normalization in Convolutional Neural Networks for Computational Pathology. *Medical Image Analysis Vol. 58*, 1-9.

Wang, F., & Preininger, A. (2019). AI in Health: State of the Art, Challenges, and Future Directions. *IMIA Yearbook of Medical Informatics*, 16-26.

Wang, J., & Liu, X. (2021). Medical image recognition and segmentation of pathological slices of gastric cancer based on Deeplab v3+ neural network. *Computer Methods and Programs in Biomedicine Vol. 207*, 1-6.

Xue, Y., Xu, T., Zhang, H., Long, R., & Huang, X. (2018). SegAN: Adversarial Network with Multi-scale. *Neuroinformatics*.

Zhang, Y., Liu, H., & Hu, Q. (2021). TransFuse: Fusing Transformers and CNNs for Medical Image Segmentation. *International Conference on Medical Image Computing and Computer-Assisted Intervention*, 109-119.