TEKNOFEST

HAVACILIK VE TEKNOLOJİ FESTİVALİ

SAĞLIK SEKTÖRÜNDE YAPAY ZEKA YARIŞMASI PROJE SUNUM RAPORU

Proje Adı: 12 Derivasyonlu EKG Tanısı

Team Name: SanitasAI

Takım ID: 893761

Başvuru ID: 4868006

İÇINDEKILER

1. TAKIM ŞEMASI 1
2. PROBLEME EN YAKIN ÇÖZÜM SUNAN ULUSLARARASI MAKALELERİN ÖZETİ 1
2.1. Tanımlar 1
2.2. Model Mimarları 2
3. VERİ VE YÖNTEM 2
3.1. Kullanılan Veri Seti ve Etiketler 2
3.2. Etiket Güvenilirliği ve Veri Kalitesi Kontrolü 3
3.3. Veri Dengesizliği Nasıl Ele Alındı 3
3.4. Veri Bölme ve Deney Protokolü 4
4. DENEY TASARIMI, SONUÇLAR VE İNCELEME 4
4.1. Sinyal Bölgesi / Zaman Aralığı Seçimi 4
4.2. Performans Metrikleri ve Hata Analizi 4
4.3. " Model Neden Bu Kararı Verdi?" 5
4.4. Yanlış Sınıflanan Örneklerin İncelenmesi 5
5. YAKLAŞIMIN GEREKÇESİ, TEKNİK EVRİM VE KAYNAK KULLANIMI 6
5.1. Neden Bu Algoritma? 6
5.2. Alternatifler Neden Elendi? 7
5.3. Parametre Seçimi ve Deneysel Ayarlar 8
5.4. Öğrenme Süreci ve Teknik Evrim 8
5.5. Hesaplama Kaynakları ve Çalıştırılabilirlik 8
5.6. Çok Sınıflı ve Çok Etiketli Formülasyon 8
6. REFERANSLAR 10

TEKNOFEST İSTANBUL HAVACILIK, UZAY VE TEKNOLOJİ FESTİVALİ

1. TAKIM ŞEMASI

Ekip Lideri: Tüm çalışmaları denetlemek, ekip üyelerinin ilerlemesini kontrol etmek, ayrıca teknik ve teknik olmayan görevleri özetlemek ve koordine etmek.

A.I. Geliştiricisi: Veri ön işleme aşamasından model eğitiminin gerçekleştirilmesine kadar algoritma modellerini tasarlamak ve uygulamak.

Araştırmacı: En iyi ve en uygun algoritmaları analiz etmek. Araştırma sürecinin tamamını belgelemek, teknik raporlar hazırlamak ve bilimsel standartlara uygunluğu sağlamak.

2. PROBLEME EN YAKIN ÇÖZÜM SUNAN ULUSLARARASI MAKALELERİN ÖZETİ

Bu projede, çok sınıflı EKG sınıflandırmasına yönelik derinlemesine araştırmalara odaklanarak son 10 yıla ait uluslararası literatürü kapsamlı bir şekilde inceledik. 12 derivasyonlu EKG verilerini kullanarak ritim anormalliklerini (aritmiler) ve iletim bozukluklarını ele alan çalışmalara öncelik verdik.

2.1. Tanımlar

- **12 Derivasyonlu ECG Veri**

EKG derivasyonu, birkaç EKG elektrotundan gelen verilerin analiz edilmesiyle hesaplanan, kalbin elektriksel aktivitesinin grafiksel bir temsilidir. 12 derivasyonlu EKG, 12 derivasyonu kaydeder ve bir EKG kağıdında 12 ayrı grafik oluşturur [1]. 12 derivasyonlu EKG verilerinden, kalp aktivitesinde bir anormallik olup olmadığını veya kalbin normal çalışıp çalışmadığını sınıflandırabiliriz. Bu projede, kalbi normal, aritmik ve iletim bozukluğu olmak üzere üç kategoriye ayıracağız.

- **Ritim Bozukluğu**

Kardiyak aritmi, kalbin elektrik sistemindeki bir grup bozukluktur ve kalp ritminin anormal, çok hızlı, çok yavaş veya düzensiz olmasına neden olur [2]. 12 derivasyonlu EKG verilerinde, aritmi, kalp ritmi modelinden sapma ile gösterilir.

- **İletim Bozukluğu**

Kalpteki iletim bozuklukları, kalbin elektriksel iletim sisteminde elektriksel uyarıların yayılmasının engellenmesine veya kesintiye uğramasına neden olan bozukluklardır ve bu durum EKG dalgalarının morfolojisi ve süresinde karakteristik değişiklikler şeklinde kendini gösterir [3]. 12 derivasyonlu EKG verilerinde, iletim bozukluğu dalgaların morfolojisi veya şekillerindeki değişikliklerle ortaya çıkar.

2.2. Model Mimarları

Gaurhar, Tiwari ve Deora [4], 500 Hz II. Derece EKG sinyallerinden iletim bozukluklarını, ritim bozukluklarını ve erken kasılmaları sınıflandırmak için büyük bir çekirdeğe sahip 1D-CNN önermiştir. Modelleri, Chapman veri setinde %98,00'lik bir F1 puanı elde ederek, CNN'nin iletim bloğu tespiti için QRS morfolojisini etkili bir şekilde yakaladığını göstermiştir. Bu çalışmadan esinlenerek, mimarimizde birincil özellik çıkarıcı olarak CNN katmanlarını kullandık. Bu katmanlar, şekil, genlik ve süre kalıpları dahil olmak üzere yerel dalga formu özelliklerini doğrudan EKG sinyalinden öğrenir. Bu, sinyaldeki morfolojik değişikliklerle tanımlanan iletim anormalliklerini tespit etmek için özellikle önemlidir. Aynı zamanda, çıkarılan özellikler, zamansal modelleme ile birleştirildiğinde aritmi kalıplarını ayırt etmenin temelini oluşturur.

Yaser ve meslektaşları [5], hasta arası değişkenlik, sinyal gürültüsü ve ritim karmaşıklığını ele almak için Zamansal Evrişimli Ağları (TCN) ile Grafik Evrişimli Ağları birleştiren bir aritmi tespit sistemi geliştirdiler. Chapman-Shaoxing 12-derivasyonlu EKG Veritabanını kullanarak, 11 ritim sınıfını dört üst sınıfa birleştirdiler ve %95,5 doğruluk elde ettiler. Bu çalışmadan esinlenerek, kalp atışları arasında uzun menzilli zamansal bağımlılıkları yakalamada mükemmel bir yetenek sergilediği için TCN'yi mimarimize zamansal modelleme modülü olarak dahil ettik.

Bu literatür incelemesine dayanarak, iki tür görevimize uyarlanmış bir hibrit mimari yaklaşımı benimseyeceğiz. QRS genişlemesi ve şekil değişiklikleri dahil olmak üzere morfolojik anormalliklerin tanımlanmasını gerektiren EKG özellik çıkarıcı ve iletim bozukluğu sınıflandırması için CNN tabanlı bir mimari kullanacağız. Ritmik kalıpları ve zamansal bağımlılıkları yakalamayı gerektiren aritmi sınıflandırması için ise birincil mimarimiz olarak TCN'yi seçeceğiz.

3. VERİ VE YÖNTEM

3.1. Kullanılan Veri Seti ve Etiketler

Bu proje için, PhysioNet üzerinde barındırılan ve kamuya açık büyük bir klinik veri seti olan PTB-XL elektrokardiyografi veri setini [6] kullandık. Bu veri seti, 18.869 farklı hastadan alınan 10 saniye uzunluğunda 21.799 klinik 12 derivasyonlu EKG kaydını içermektedir. Veriler yaklaşık yedi yıl boyunca toplanmış olup, geniş bir demografik aralığı kapsamaktadır (%52 erkek, %48 kadın; yaş aralığı 0–95, medyan yaş 62) [6]. Ham dalga formu verileri, 16 bit hassasiyetle 500 Hz örnekleme frekansında sağlanır ve .dat ile .hea dosyalarından oluşan WaveForm DataBase (WFDB) formatında depolanır.

Her kayıt, SCP-ECG standardına uygun, kardiyologlar tarafından doğrulanmış en fazla iki açıklama ile etiketlenmiştir. Yarışmanın 1. Aşama gerekliliklerine uygun olarak, veri setinin

tanısal üst sınıf etiketlerinden yararlanarak bu ayrıntılı açıklamaları, veri setinin tanısal üst sınıf etiketlerinden yararlanarak gerekli üç üst sınıfa eşledik:

Aritmiler/Ritmi bozukluğu: Veri kümesindeki ritimle ilgili ifadelerden eşleştirilmiştir; bunlar arasında atriyal

fibrilasyon (AFIB), atriyal flutter (AFL), supraventriküler taşikardi (SVT) ve prematüre kasılmalar yer almaktadır.

İletim Bozukluğu: Sol dal bloğu (LBBB), sağ dal bloğu (RBBB) ve çeşitli AV blok tiplerini içeren İletim Bozukluğu (CD) üst sınıfından eşleştirildi.

Normal EKG: Normal (NORM) üst sınıfından ve Sinüs Ritiminden (SR) eşleştirilmiştir; klinik olarak önemli anormallikleri olmayan sağlıklı kontrol grubundan alınan kayıtları temsil eder.

3.2. Etiket Güvenilirliği ve Veri Kalitesi Kontrolü

PTB-XL veri seti, kardiyologlar tarafından doğrulanmış yüksek kaliteli açıklamalar sağlar ve sinyal kalitesi meta verilerini içerir. Aşağıdaki ön işleme ve kalite kontrol adımlarını gerçekleştirdik: Kırpma ve Dolgu, Bant geçidi filtreleme (0,5-40 Hz), Yeniden örnekleme ve Normalleştirme.

3.3. Veri Dengesizliği Nasıl Ele Alındı

Model geliştirilmeden önce veri setinin sınıf dağılımı analiz edildi. Üç üst sınıf etiketinin oranları yaklaşık olarak %59,4 (Normal), %23,5 (Aritmi) ve %17,1 (İletim) idi. Veri seti mükemmel bir şekilde dengeli olmasa da, bu dengesizlik seviyesi ciddi değil, orta düzeyde kabul edilmektedir.

Sınıf dengesizliğinin model performansı üzerindeki potansiyel etkisini araştırmak için iki yaklaşım değerlendirildi:

- Ağırlıklı Rastgele Örnekleme
- Sınıf ağırlıklı çapraz entropi kaybı; burada ağırlıklar, sınıf sıklıklarıyla ters orantılıydı

Deney sonuçları, sınıf ağırlıklarının dahil edilmesinin makro F1 puanı gibi performans metriklerinde anlamlı bir iyileşmeye yol açmadığını gösterdi. Bu, modelin dengesizliğe rağmen tüm sınıflar için temsili özellikleri öğrenebildiğini göstermektedir. Bu davranış, her sınıfın yeterli temsiline atfedilebilir: azınlık sınıflar bile birkaç bin örnek içeriyordu ve bu da etkili öğrenme için yeterli veri sağladı.

3.4. Veri Bölme ve Deney Protokolü

Veri kümesi, 80–10–10 oranında bir bölünme kullanılarak eğitim, doğrulama ve test kümelerine ayrılmıştır. Eğitim kümesi model parametrelerini optimize etmek için, doğrulama kümesi hiperparametre ayarlaması ve erken durdurma için kullanılmış, test kümesi ise yalnızca nihai performans değerlendirmesi için ayrılmıştır.

4. DENEY TASARIMI, SONUÇLAR VE İNCELEME

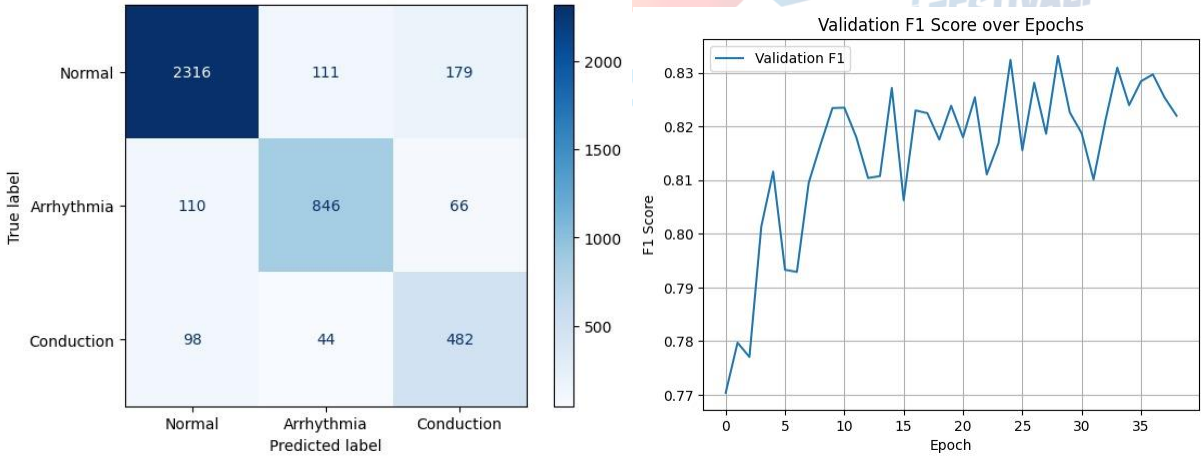
4.1. Sinyal Bölgesi / Zaman Aralığı Seçimi

Çeşitli nedenlerden ötürü açık bir zaman aralığı veya sinyal bölgesi seçimi uygulamadık. İlk olarak, iletim bozuklukları genellikle birden fazla kalp atışında tutarlı örüntüler gerektirdiğinden, keyfi segmentasyonun etkinliği azalır. İkinci olarak, deneylerimizden elde edilen karışıklık matrisinin analizi, modelin en sık normal vakalarla iletim bozukluğu vakalarını karıştırdığını gösterdi; bu nedenle bu sorunun çözülmesine öncelik verildi.

Bunu çözmek için, modelin sinyalin en bilgilendirici kısımlarına odaklanmasını sağlayan bir zamansal dikkat toplama mekanizması ekledik. Bu değişiklik, F1 puanında yaklaşık %2'lik bir iyileşme sağladı.

4.2. Performans Metrikleri ve Hata Analizi

Bu çalışmada kullanılan birincil değerlendirme metriği, yarışma kurallarında belirtildiği üzere makro F1 skoru. Nihai model, test setinde %81,7'lik bir makro F1 skoru elde ederken, doğrulama setinde %83,2'lik en yüksek skora ulaştı. Genel F1 skoruna ek olarak, sınıf bazında davranışı daha iyi anlamak için karışıklık matrisi kullanarak model performansını analiz ettik.



Şekil 1. *Karışıklık Matrisi and F1-Skoru*

Sonuçlar şunu göstermektedir:

- Model, Normal sınıfında yüksek performans göstererek yüksek hassasiyet ve geri çağırma oranlarına ulaşmaktadır.
- Aritmi sınıfındaki performans da tatmin edicidir ve zamansal ritim kalıplarının başarılı bir şekilde modellenmiş olduğunu göstermektedir.
- En zorlu sınıf, sıklıkla Normal EKG sinyalleriyle karıştırılan İletim Bozukluğu sınıfıdır.

Bu karışıklık, iletim anormalliklerinin bazen normal kalıplardan ayırt edilmesi zor olan ince morfolojik değişiklikler sergilemesi ile açıklanabilir; bu durum özellikle gürültü ve hastalar arası değişkenlik altında daha belirgindir.

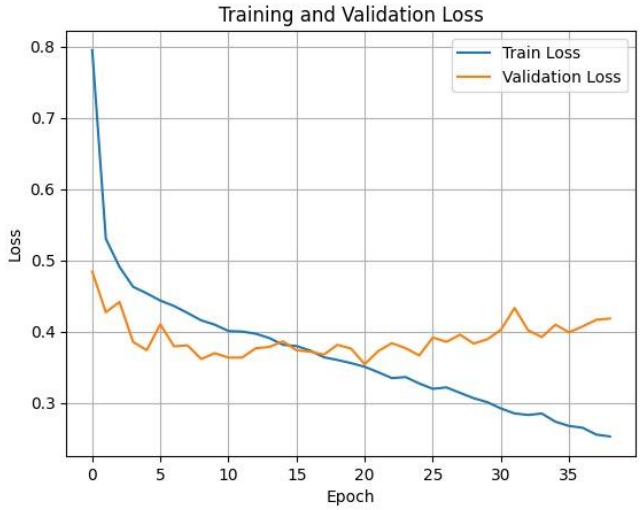
4.3. " Model Neden Bu Kararı Verdi?"

Yorumlanabilirliği artırmak için, modelin iç davranışını analiz ettik ve özellikle mimaride kullanılan dikkat mekanizmalarına odaklandık. Zamansal dikkat havuzu katmanı, modelin EKG sinyali içindeki belirli zaman bölgelerine daha fazla önem vermesini sağlar. Dikkat ağırlıklarının görselleştirilmesi, modelin QRS kompleksleri ve düzensiz ritim kalıpları gibi belirgin dalga formu özellikleri içeren segmentlere odaklanma eğiliminde olduğunu gösterdi.

4.4. Yanlış Sınıflanan Örneklerin İncelenmesi

Modelin sınırlarını daha iyi anlamak için, karışıklık matrisi kullanarak yanlış sınıflandırılan örnekleri analiz ettik. En sık görülen yanlış sınıflandırma, "Normal" ve "İletim Bozukluğu" sınıfları arasında meydana geldi; bu durum, bazı iletim anormalliklerinin çok ince morfolojik sapmalar sergilediğini, gürültü ve hastalar arası değişkenliğin ise ayırt edici özellikleri daha da belirsiz hale getirebileceğini göstermektedir. Ek olarak, daha az sayıda Aritmi vakası Normal olarak yanlış sınıflandırıldı; bu durum genellikle düzensiz ritim kalıplarının zayıf olduğu veya sadece kısa bir süre mevcut olduğu durumlarda görüldü. Bu bulgular iki temel zorluğu vurgulamaktadır: ince morfolojik değişiklikleri tespit etmenin zorluğu ve uzun vadeli zamansal bağımlılıkları yakalamanın önemi. Gelecekteki iyileştirmeler, sınırda olan vakaları daha iyi ayırt etmek için daha güçlü özellik çıkarma veya alana özgü kısıtlamaların dahil edilmesini içerebilir.

4.5. Eğitim ve Doğrulama Kayıp Eğrileri



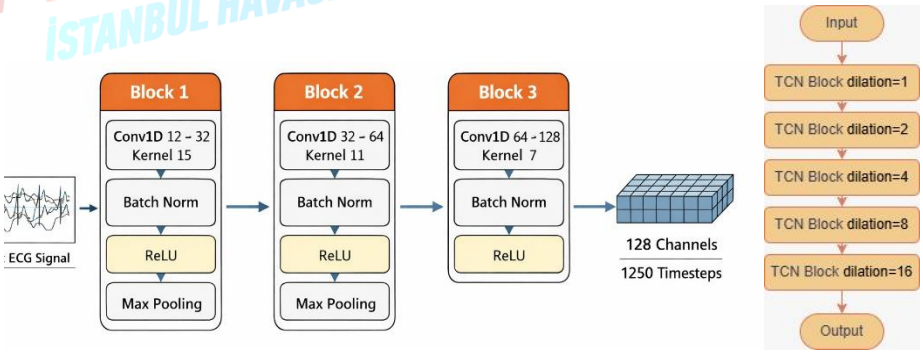
Şekil 2. *Eğitim ve Doğrulama Kayıp Eğrileri*

Doğrulama kaybına dayalı erken durdurma, aşırı eğitimin önlenmesine de yardımcı oldu.

5. YAKLAŞIMIN GEREKÇESİ, TEKNİK EVRİM VE KAYNAK KULLANIMI

5.1. Neden Bu Algoritma?

EKG sinyallerinin hem zamansal hem de morfolojik özelliklerini etkili bir şekilde yakaladığı için hibrit bir CNN + TCN mimarisi seçtik. Evrişimli Sinir Ağları (CNN), iletim bozukluklarının tespitinde hayati öneme sahip olan QRS kompleksi şekli gibi yerel morfolojik özellikleri çıkarmada oldukça etkilidir [4]. Bu özellik, kalp atışlarının birçoğunda ortaya çıkan kalp ritmi bozukluklarının tespitinde bu ağları özellikle etkili kılmaktadır. Öte yandan, Zamansal Evrişimli Ağlar (TCN), genişletilmiş evrişimler ve kalıntı bağlantılar aracılığıyla sıralı verilerdeki uzun menzilli bağımlılıkları modellemek için çok uygundur [5].



Şekil 3. *TCN Blok ve TCN Mimarı*

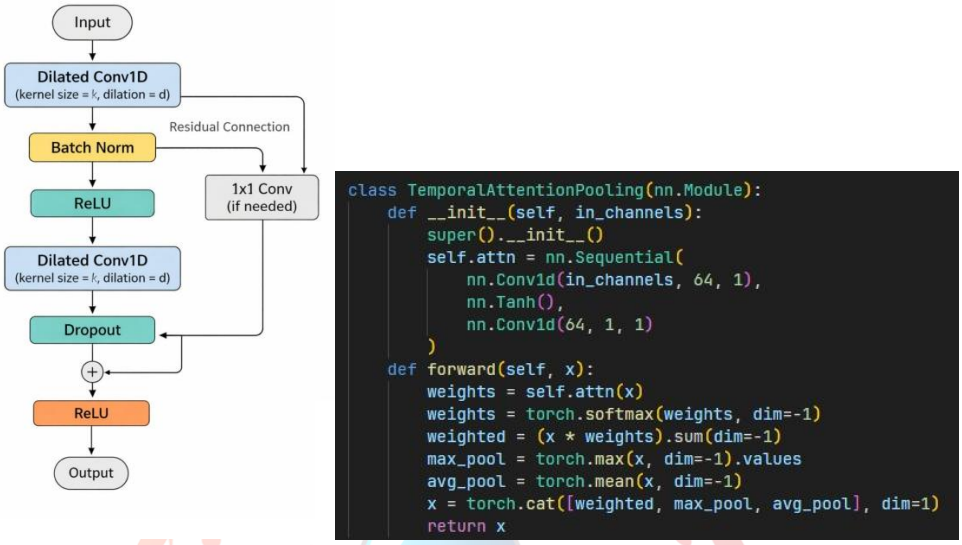


Figure 4. *CNN Mimari ve Dikkat Havuzlama Mekanizmasını*

Ayrıca, modelin EKG sinyalinin en bilgilendirici bölgelerine odaklanma yeteneğini geliştirmek için zamansal dikkat havuzlama mekanizmasını (Temporal Attention Pooling) da dahil ettik. Bu mekanizma, tüm zaman adımlarını eşit şekilde ele almak yerine, sınıflandırma için daha alakalı olan segmentlere daha fazla önem atayarak, modelin kritik kalıpları yakalama yeteneğini geliştirir.

5.2. Alternatifler Neden Elendi?

Son CNN + TCN + sınıflandırıcı yaklaşımını seçmeden önce birkaç alternatif model mimarisi değerlendirildi. Bu alternatifler, EKG sinyallerindeki zamansal örüntüleri yakalama yetenekleri, hesaplama verimliliği ve ilk deneylerdeki performansları temelinde değerlendirildi.

1) Düz CNN: Standart CNN'ler her bir derivasyondan yerel özellikleri çıkarabilse de, kalp atışları arasındaki uzun menzilli zamansal bağımlılıkları açıkça yakalayamazlar. İlk deneyler, genellikle çoklu atım bağlamı gerektiren iletim anormalliklerinde yalnızca CNN içeren bir modelin zorlandığını gösterdi.
2) RNN / LSTM tabanlı modeller: Tekrarlayan mimariler zamansal dizileri modelleyebilir ve potansiyel alternatifler olarak test edilmiştir. İlk deneylerdeki performans, CNN+TCN kombinasyonuyla karşılaştırılabilir veya biraz daha kötüydü.

5.3. Parametre Seçimi ve Deneysel Ayarlar

Parameter	Deneysel Ayarlar
Learning rate	1e-4
Batch size	32
Number of epochs	15-25
Optimizer	AdamW
scheduler	CosineAnnealingLR
Regularization	L2 1e-4
Dropout rate	0.5
Early stopping	yes

Tablo 1. *Parametre Seçimi ve Deneysel Ayarlar*

5.4. Öğrenme Süreci ve Teknik Evrim

Başlangıçta, basit CNN tabanlı mimarilerle deneyler yaptık. Bu modeller yerel özellikleri çıkarabilse de, uzun vadeli zamansal bağımlılıkları yakalamakta zorlandılar ve bu da aritmi tespiti için yetersiz bir performansla sonuçlandı. Daha sonra LSTM gibi tekrarlayan modelleri inceledik, ancak özellikle veri setinin büyüklüğü göz önüne alındığında, yavaş eğitim ve aşırı uyum sorunlarıyla karşılaştık. Literatür taraması ve deneysel sonuçlara dayanarak, özellik çıkarıcı olarak CNN'yi kullanan TCN'ye geçtik. Bu, modelin hem morfolojik hem de zamansal kalıpları yakalamasını sağlayarak performansı önemli ölçüde artırdı.

Aşağıdakiler sayesinde daha da iyileştirmeler sağlandı:

- F1 skorunu yaklaşık %2 oranında iyileştiren zamansal dikkat havuzlamasının (Temporal Attention Pooling) eklenmesi
- Aşırı uyumlanmayı azaltmak için dropout ve ağırlık azalması gibi düzenleme tekniklerinin uygulanması

5.5. Hesaplama Kaynakları ve Çalıştırılabilirlik

Tüm deneyler, yaklaşık 12–16 GB RAM ile Google Colab ve Kaggle üzerinden NVIDIA Tesla T4 GPU'lar olmak üzere bulut tabanlı GPU ortamları kullanılarak gerçekleştirilmiştir. Eğitim süresi tam bir döngü başına ortalama 35 dakika civarında iken, kayıt başına çıkarım süresi 10 milisaniyeden azdı.

5.6. Çok Sınıflı ve Çok Etiketli Formülasyon

Çoklu sınıf yaklaşımında, her EKG kaydı tam olarak bir sınıfa (Normal, Aritmi veya İletim Bozukluğu) atanır. Ancak, gerçek klinik senaryolarda, tek bir EKG'de aynı anda birden fazla

anormallik görülebilir. Bu nedenle, her bir örneğin birden fazla sınıfa ait olabileceği çok etiketli bir yaklaşım da incelenmiştir.

Bunu değerlendirmek için modelin çıktı katmanını ve kayıp fonksiyonunu değiştirdik:

- Çok sınıflı: Çapraz Entropi Kaybı ile Softmax aktivasyonu
- Çok etiketli: İkili Çapraz Entropi Kaybı ile Sigmoid aktivasyonu

Deney sonuçları şunu gösterdi:

- Çok sınıflı sınıflandırma yaklaşık %81 F1 puanı elde etti
- Çok etiketli sınıflandırma yaklaşık %86 F1 skoru elde etti

Bu iyileşme, çok etiketli formülasyonun verilerin altta yatan yapısını daha iyi yansıttığını ve modelin örtüşen patolojik durumları daha etkili bir şekilde yakalamasını sağladığını göstermektedir. Ancak, performansın iyileşmesine rağmen, Aşama 1 için yarışma kuralları gereği nihai model çok sınıflı yapılandırma kullanılarak uygulandı.

TEKNOFEST
İSTANBUL HAVACILIK, UZAY VE TEKNOLOJİ FESTİVALİ

6. REFERANSLAR

[1] I. Tomašić and R. Trobec, "Electrocardiographic systems with reduced numbers of leads-synthesis of the 12-lead ECG," *IEEE Reviews in Biomedical Engineering,* vol. 7, pp. 126-142, 2013.

[2] A. Nagpal, A. Pundkar, A. Singh and C. Gadkari, "Cardiac Arrhythmias and Their Management: An In-Depth Review of Current Practices and Emerging Therapies," *DMIHER Datta Meghe Medical Collage,* vol. 16, no. 8, pp. 1-8, 2024.

[3] R. d. Silva and A. d. S. Maciel, "Conduction Disorders : The Value of Surface ECG," *Current Cardiology Reviews,* vol. 17, no. 2, pp. 173-181, 2021.

[4] S. Gaurhar, A. K. Tiwari and S. Deora, "A CNN-Based Classifier for Detecting Rhythm Disorders, Premature Contractions, and Conduction Abnormalities From ECG," *Biomedical Signal Processing and Control,* vol. 113, p. 108834, 2026.

[5] S. Yaser, M. Chowdhury and R. Sarmun, "SER Inspired Deep Learning Approach to Detect Cardiac Arrhythmias in Electrocardiogram Signals Using Temporal Convolutional Network and Graph Neural Network," *Computers in Biology and Medicine,* vol. 195, pp. 1-10, 2025.

[6] P. Wagner, N. Strodthoff, R.-D. Bousseljot, W. Samek and T. Schaeffter, "PTB-XL, a large publicly available electrocardiography dataset (version 1.0.3)," PhysioNet, 2022.

TEKNOFEST İSTANBUL HAVACILIK, UZAY VE TEKNOLOJİ FESTİVALİ