TEKNOFEST
HAVACILIK VE TEKNOLOJİ FESTİVALİ

SAĞLIK SEKTÖRÜNDE YAPAY ZEKA YARIŞMASI PROJE DETAY RAPORU

12 Dereceli EKG Kayıtlarından Üst Sınıf Kalp Hastalığı Sınıflandırması

Lise Seviyesi
Proje Adı: EKG Temelli Aritmi ve İletim Bloklarının Sınıflandırılması için Hibrit TCN-CNN Yaklaşımı
Takım Adı: SanitasAI Takım
Kimliği: 8G3761
Başvuru Kimliği: 4868006

İÇİNDEKİLER

1. TAKIM ŞEMASI 1
2. PROBLEME EN YAKIN ÇÖZÜM SUNAN ULUSLARARASI MAKALELERİN ÖZETİ 1
2.1. Challenges in ECG Classification ..... Error! Bookmark not defined.
2.2. Review of Previous Studies 1
2.3. Discussion ..... Error! Bookmark not defined.
3. VERİ VE YÖNTEM 2
3.1. Kullanılan Veri Seti ve Etiketler 2
3.2. Etiket Güvenilirliği ve Veri Kalitesi Kontrolü 3
3.3. Veri Dengesizliği Nasıl Ele Alındı 3
3.4. Veri Bölme ve Deney Protokolü 3
4. DENEY TASARIMI, SONUÇLAR VE İNCELEME 4
4.1. Sinyal Bölgesi / Zaman Aralığı Seçimi 4
4.2. Performans Metrikleri ve Hata Analizi 4
4.3. “Model Neden Bu Kararı Verdi?” 5
4.4. Yanlış Sınıflanan Örneklerin İncelenmesi 6
5. YAKLAŞIMIN GEREKÇESİ, TEKNİK EVRİM VE KAYNAK KULLANIMI 6
5.1. Neden Bu Algoritma / Mimari? 6
5.2. Alternatifler Neden Elendi? 7
5.3. Parametre Seçimi ve Deneysel Ayarlar 8
5.4. Öğrenme Süreci ve Teknik Evrim 8
5.5. Hesaplama Kaynakları ve Çalıştırılabilirlik 9
REFERANSLAR 10

TEKNOFEST
İSTANBUL HAVACILIK, UZAY VE TEKNOLOJİ FESTİVALİ

1. TAKIM ŞEMASI

Takım Rolleri	Görevler
Takım Lideri	Tüm çalışmaları denetlemek, üyelerin ilerlemesini kontrol etmek ve ayrıca ve teknik ve teknik olmayan görevleri koordine eder.
Yapay Zeka Geliştiricisi	Veri ön işleme aşamasından modelin eğitilmesine kadar algoritma modellerini tasarlar ve uygular.
Araştırmacı	En iyi ve en uygun algoritmaları analiz etmek. Tüm araştırma sürecini belgelemek, teknik raporlar yazmak ve bilimsel standartlara

Tablo 1. *Takım şeması*

2. PROBLEME EN YAKIN ÇÖZÜM SUNAN ULUSLARARASI MAKALELERİN ÖZETİ

2.1. EKG Sınıflandırmasındaki Zorluklar

12 derivasyonlu EKG'leri sınıflandırmak zordur, çünkü sinyaller hem yerel morfolojik özellikleri (örn. P dalgası şekli, QRS genişliği) hem de genel zamansal kalıpları (örn. R-R aralıkları) içeren oldukça değişken zaman serileridir [1]. Hastalar arası değişkenlik, elle oluşturulmuş sabit bir özellik kümesinin iyi bir şekilde genelleştirilmesini engeller.

Ayrıca, farklı durumlar sinyalin farklı yönlerine dikkat edilmesini gerektirir. AFIB/AFL'de ritim düzensizliklerini tespit etmek için birden fazla atım boyunca analiz yapılması gerekir [2], oysa LBBB/RBBB ise tek bir atım içindeki ince dalga formu bozulmalarıyla ayırt edilir [3]. Bu ikili yapı, yüzeysel modelleri etkisiz kılar.

2.2. Review of Previous Studies

Makale	Model	F1 Macro	Önemli Çıkarım
[1]	CNN, LSTM, CNN-LSTM hybrid	F1 ~92%	Morfoloji için CNN ile ritim için LSTM'yi ritim için en iyi dengeyi sağlar.
[2]	CNN + RNN with attention	F1 ~89%	Dikkat mekanizmaları, modelin klinik açıdan önemli zaman dilimlerine ve ipuçlarına odaklanmasına yardımcı olur.
[3]	Multi-scale CNN + Transformer	F1 = 81.2%	Transformer, bu kalp atışları arasındaki ilişkileri kalp atışları arasındaki ilişkileri yakalamada mükemmeldir, ancak hesaplama açısından yüksektir.
[4]	TCN + GCN	F1 = 95.5%	TCN, aritmi sınıflandırması için zamansal ritim kalıplarını yakalamada mükemmeldir; genişletilmiş konvolüsyonlar çok ölçekli özellik çıkarılmasını sağlar

[5]	TCN + Bi-LSTM + Attention	F1 = 99.56%	Çoklu görünüm özellik çıkarma ile dikkat mekanizmaları performansı performansı ve ritim bozukluklarında yorumlanabilirliği

Tablo 2. *Önceki Modellerle Karşılaştırma*

2.3. Çözüm

Önceki çalışmalar, EKG sınıflandırmasının hem morfolojik hem de zamansal özelliklerin çıkarılmasını gerektirdiğini göstermektedir. CNN tabanlı yaklaşımlar dalga formu morfolojisini etkili bir şekilde yakalarken, genişletilmiş konvolüsyonlara sahip TCN'ler [6] gibi zamansal modeller, birden fazla atımdaki ritim değişikliklerini yakalar. Bu nedenle, bu çalışmada bu birbirini tamamlayan temsilleri birleştirmek için bir CNN-TCN mimarisi benimsenmiştir.

3. VERİ VE YÖNTEM

3.1. Kullanılan Veri Seti ve Etiketler

Bu yarışmanın ana veri seti, Teknofest tarafından sağlanan ve 500 Hz frekansında örneklenmiş 12 derivasyonlu EKG kayıtlarını içeren veri setidir. Her kayıt 10 saniye sürmektedir (derivasyon başına 5000 örnek). Bu görev için yalnızca resmi yarışma veri seti kullanılmıştır; harici veri setleri dahil edilmemiştir.

Sınıflandırma görevi, her EKG kaydının beş sınıftan tam olarak birine ait olduğu çok sınıflı bir sorundur:

Sınıf	Label	Açıklama
0	Normal	Normal sinüs ritmi ile sağlıklı EKG
1	AFIB	Atriyal Fibrilasyon – düzensiz R-R aralıkları, P dalgalarının yokluğu
2	AFL	Atriyal Flutter – testere dişi şeklinde flutter dalgaları, düzenli ventriküler yanıt
3	LBBB	Sol Dal Bloğu – genişlemiş QRS, lateral derecelerde
4	RBBB	Sağ Dal Bloğu – genişlemiş QRS, V1-V2 derivasyonlarında "rSR'"

Tablo 3. *Sınıfların açıklamaları*

Sınıf	**Training Samples**	**Validation Samples**	**Test Samples**	**Toplam**
Normal	700	150	150	1000
AFIB	700	150	150	1000
AFL	700	150	150	1000
LBBB	700	150	150	1000
RBBB	700	150	150	1000
Toplam	3500	750	750	5000

Tablo 4. *Sınıf Dağılımı*

3.2. Etiket Güvenilirliği ve Veri Kalitesi Kontrolü

Etiketler yarışma organizatörleri tarafından sağlanmış ve herhangi bir değişiklik yapılmaksızın gerçek değer olarak kabul edilmiştir. Ancak, modele tutarlı girdi sağlamak amacıyla ham sinyaller üzerinde kalite kontrolü gerçekleştirilmiştir.

Ön İşleme Süreci:

- NaN İşleme: NaN değerleri içeren tüm kayıtlar, her bir elektrot için doğrusal olarak enterpolasyona tabi tutulmuştur.
- Yeniden Örnekleme: Tüm sinyaller, 500 Hz hedef örnekleme hızına göre yeniden örneklendi.
- Bant Geçiş Filtreleme: Baz çizgisi sapmasını ve yüksek frekanslı gürültüyü gidermek için 4. dereceden Butterworth bant geçiş filtresi (0,5–40 Hz) uygulandı.
- Uzunluk Standartlaştırması: Tüm kayıtlar, kenar doldurma yöntemi kullanılarak tam olarak 5000 örnek (10 saniye) olacak şekilde dolduruldu veya kesildi.
- Normalleştirme: Her bir elektrot, zamansal boyut boyunca bağımsız olarak z-skoruna göre normalleştirildi (ortalama sıfır, varyans birim).

Eğitim genişletmesi, sağlamlığı artırmak amacıyla genlik ölçeklendirme, Gauss gürültüsü enjeksiyonu, zamansal kaydırma, baz çizgisi kayması simülasyonu, zaman maskeleme ve hafif zaman uzatmayı içermiştir.

Kalite denetimi sırasında 19 kayıt bozuk olarak tespit edildi ve eğitimden çıkarıldı. Bunlar 2 Normal, 8 AFIB, 5 AFL, 2 RBBB ve 2 LBBB örneklerinden oluşuyordu.

3.3. Veri Dengesizliği Nasıl Ele Alındı

Yarışma veri kümesi, beş sınıfın tümü arasında dengelidir; eğitim, doğrulama ve test bölümlerinde her sınıf için eşit sayıda örnek bulunmaktadır (sınıf başına 700/150/150).

Veri kümesi dengeli olduğu için, sınıf ağırlıklandırması yapılmadan standart Çapraz Entropi Kaybı kullanılmıştır. Veri kümesi dengeli olduğu için, sınıf ağırlıklandırması yapılmadan standart Çapraz Entropi Kaybı kullanılmıştır. Makro F1 puanı, resmi yarışma metriği olması ve tüm sınıflara eşit önem vermesi nedeniyle birincil metrik olarak seçilmiştir.

3.4. Veri Bölme ve Deney Protokolü

Model performansını sağlam bir şekilde değerlendirmek ve nihai test için en iyi modeli seçmek amacıyla 5 katmanlı tabakalı çapraz doğrulama yöntemi kullanıldı.

Bölme Protokolü:

- Resmi eğitim ve doğrulama bölümleri, sınıf başına toplam 850 örnek içeriyordu (700 eğitim ve 150 doğrulama örneği). Çapraz doğrulama deneyleri için, sınıf başına bu 850 örnek birleştirildi ve tabakalı 5 katlı çapraz doğrulama kullanılarak yeniden dağıtıldı.
- Her katman, eğitme için verilerin 4/5'ini (sınıf başına 560 örnek) ve doğrulama için 1/5'ini (sınıf başına 140 örnek) kullanmıştır.
- Tabakalaştırma, her katın sınıf dağılımını korumasını sağlamıştır.

Model Seçimi:

- Her kat için, en fazla 100 epok boyunca eğitim gerçekleştirildi.
- Doğrulama Makro F1 değerine göre erken durdurma (sabır = 10) uygulandı.
- Her katmandan en iyi model, en yüksek doğrulama F1 değerine göre kaydedildi.

4. DENEY TASARIMI, SONUÇLAR VE İNCELEME

4.1. Sinyal Bölgesi / Zaman Aralığı Seçimi

Önerilen model, tek tek kalp atışı segmentlerini ayıklamak yerine 10 saniyelik EKG kaydının tamamını işler. Her bir girdi, 500 Hz örnekleme frekansında her derivasyonda 5000 örnek uzunluğunda tam bir 12 derivasyonlu EKG sinyalinden oluşur.

Farklı EKG sınıflarının farklı zamansal ölçeklerde bilgiye ihtiyaç duyması nedeniyle tam kaydın kullanılması tercih edilmiştir. LBBB ve RBBB gibi iletim anormallikleri, esas olarak QRS ile ilgili değişiklikler dahil olmak üzere yerel dalga formu morfolojisiyle karakterize edilir ve bu özellikler evrişimli özellik çıkarma yöntemiyle yakalanabilir. Buna karşın, AFIB ve AFL gibi ritim bozuklukları, atımlar arası varyasyonları, ritim düzenliliğini ve atriyal aktivite kalıplarını analiz etmek için daha uzun zamansal bağlam gerektirir.

4.2. Performans Metrikleri ve Hata Analizi

Bu çalışmada kullanılan birincil değerlendirme metriği, resmi yarışma değerlendirme kriterlerine uygun olarak Makro F1 puanı olmuştur. Makro F1, beş sınıfın tümüne eşit önem verdiği ve her bir sınıfın zorluk derecesinden bağımsız olarak dengeli bir değerlendirme sağladığı için seçilmiştir.

Nihai CNN-TCN modeli, 750 EKG kaydını içeren resmi test seti üzerinde değerlendirildi. Elde edilen Makro F1 skoru %81,25 oldu. Sınıf bazında performans aşağıda gösterilmiştir.

Sınıf	**Precision**	**Recall**	**F1 Score**
Normal	90.63%	96.67%	93.55%
AFIB	66.86%	75.33%	70.85%
AFL	72.22	52.00%	60.47%
LBBB	88.75%	94.67%	91.61%
RBBB	88.89%	90.67%	89.77%
Macro ortalama	**81.47%**	**81.87%**	**81.25%**

Tablo 5. *Sınıflara Göre Test Kümesi Performans Metrikleri*

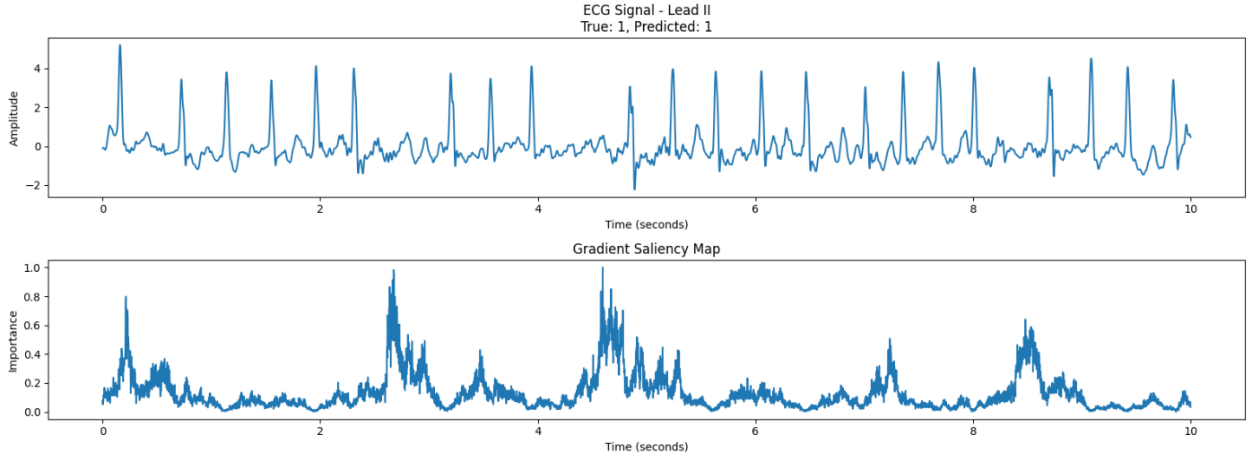
Sonuçlar, modelin Normal, LBBB ve RBBB sınıflarında %89'un üzerinde F1 puanları ile güçlü bir performans sergilediğini göstermektedir. Bu, önerilen CNN-TCN mimarisi, iletim anormallikleri ve normal EKG desenleriyle ilişkili morfolojik özellikleri başarıyla öğrendiğini göstermektedir.

Temel sınırlama, AFIB ve AFL arasındaki ayrımdı. Karışıklık matrisi, 54 AFL kaydının AFIB olarak sınıflandırıldığını, 25 AFIB kaydının ise AFL olarak sınıflandırıldığını

göstermektedir. Bu durum, modelin genel atriyal ritim anormalliklerini öğrenmiş olduğunu, ancak bu birbiriyle yakından ilişkili ritim kalıplarını ayırmakta zorluk çektiğini göstermektedir.

4.3. "Model Neden Bu Kararı Verdi?"

Modelin tahminlerini yorumlamak için gradyan tabanlı bir belirginlik yöntemi uyguladık. Belirginlik haritası, tahmin edilen sınıf puanının giriş EKG sinyaline göre mutlak gradyanı olarak hesaplanır ve 12 derivasyonun tümü üzerinden ortalaması alınır. Bu, modelin kararını en çok etkileyen zaman bölgelerini vurgulayan bir zamansal önem profili oluşturur.

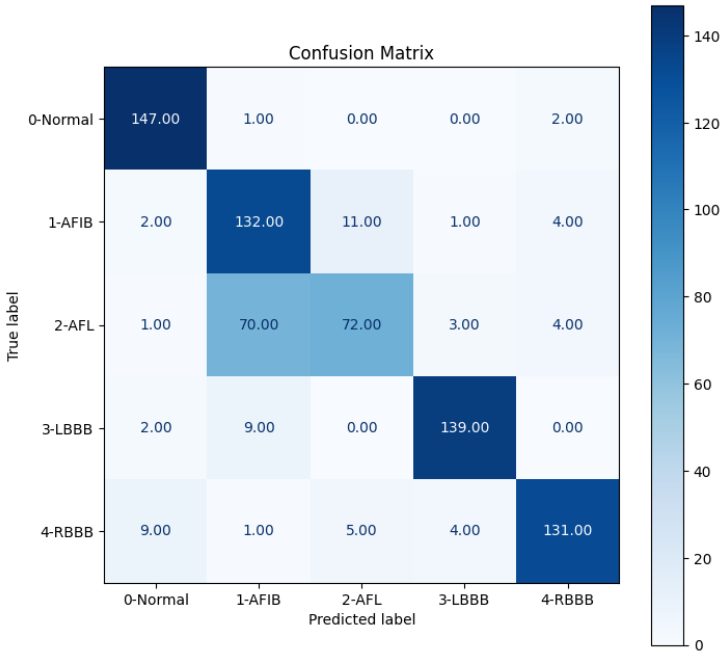


Şekil 1. *EKG Sinyalinde Gradyan Önem Haritası*

Şekil 2, II. Derlemeden (Gerçek: AFIB, Tahmin Edilen: AFIB) bir örnek göstermektedir. Önem haritası, QRS komplekslerine ve ritim değişikliklerine karşılık gelen ~0–0,3 s, ~2,5–2,8 s, ~4,5–4,9 s ve ~8,4–8,7 s civarındaki önemli bölgeleri vurgulamaktadır. Bu, modelin 10 saniyelik kayıt boyunca hem yerel dalga formu morfolojisini hem de atımdan atıma zamansal kalıpları kullandığını göstermektedir. Önemi daha düşük olan bölgeler, modelin sinyali tekdüze bir şekilde değil, tanısal açıdan ilgili segmentlere odaklandığını göstermektedir. Ancak, birden fazla kalp döngüsüne yayılmış önem derecesi, AFIB ve AFL gibi benzer ritim bozuklukları arasında karışıklığa neden olabilir.

İSTANBUL HAVACILIK, UZAY VE TEKNOLOJİ FESTİVALİ

4.4. Yanlış Sınıflanan Örneklerin İncelenmesi



Şekil 2. *Confusion Matrix*

Karışıklık matrisi analizi, sınıflandırma hatalarının çoğunun AFIB ve AFL arasında meydana geldiğini, Normal, LBBB ve RBBB'nin ise daha güvenilir bir şekilde sınıflandırıldığını göstermektedir.

En büyük hata grubu, yanlışlıkla AFIB olarak sınıflandırılan AFL kayıtlarından oluşuyordu. 150 AFL örneğinin 54'ü AFIB olarak tahmin edildi. Bu durum, muhtemelen bu iki ritim bozukluğu arasındaki benzerlikten kaynaklanmaktadır. Her ikisi de anormal atriyal elektriksel aktiviteyi içerir ve 10 saniyelik bir kayıt içinde çakışan zamansal özellikler barındırabilir; bazı AFL kayıtları daha az belirgin flutter dalga desenleri içerirken, bazı AFIB kayıtları geçici olarak düzenli ritim segmentleri sergileyebilir. Sonuç olarak, model her bir duruma özgü özellikler yerine ortak ritim özelliklerini öğrenmiş olabilir.

Buna karşılık, LBBB ve RBBB hataları nispeten sınırlıydı çünkü bu sınıflar, özellikle QRS ile ilgili desenlerde daha belirgin morfolojik farklılıklar içerir. Yanlış sınıflandırma analizi, önerilen sistemin temel sınırlamasının genel EKG temsillerini çıkarmak değil, birbiriyle yakından ilişkili atriyal ritim bozukluklarını ayırmak olduğunu göstermektedir. Gelecekteki iyileştirmeler arasında açık R-R aralığı modellemesi, atım düzeyinde işleme veya ritime özgü özellik öğrenimi yer alabilir.

5. YAKLAŞIMIN GEREKÇESİ, TEKNİK EVRİM VE KAYNAK KULLANIMI

5.1. Neden Bu Algoritma / Mimari?

Nihai mimari, EKG sinyallerinin özellikleri ve sınıflandırma görevinin gereklilikleri temel alınarak seçilmiştir. Saf bir CNN yaklaşımı, QRS morfolojisi gibi yerel morfolojik kalıpları çıkarmak için etkilidir ve bu da onu iletim anormallikleri için uygun kılar. Ancak, CNN'lerin

AFIB ve AFL gibi ritim bozuklukları için gerekli olan uzun vadeli zamansal ilişkileri modelleme yeteneği sınırlıdır. Bu nedenle, hibrit bir CNN-TCN mimarisi geliştirilmiştir. CNN kodlayıcı yerel dalga formu temsillerini çıkarırken, TCN bileşeni genişletilmiş konvolüsyonlar kullanarak birden fazla kalp atışı boyunca zamansal bağımlılıkları yakalar. Tekrarlayan mimarilerle karşılaştırıldığında, TCN paralel hesaplama verimliliğini korurken geniş bir alıcı alan sağlar.

Ayrıca, EKG sinyalleri birden fazla derivasyona dağılmış bilgiler içerir. Nihai model, 12 derivasyonun tümünü eşzamanlı olarak işler; bu sayede CNN katmanları, gereksiz parametreler eklemeden derivasyona özgü temsilleri otomatik olarak öğrenebilir.

5.2. Alternatifler Neden Elendi?

Nihai CNN-TCN mimarisi seçilmeden önce, EKG sınıflandırma performansını iyileştirmeye yönelik farklı stratejileri araştırmak amacıyla birkaç alternatif model tasarımı değerlendirilmiştir. Deneyler, özellikle zorlu AFIB ve AFL sınıfları için zamansal modelleme, çoklu derivasyon özelliklerinin kullanımı ve sınıfa özgü ayırt etme yeteneğinin iyileştirilmesine odaklanmıştır.

Değerlendirilen mimariler ve bunların doğrulama Makro F1 puanları aşağıda özetlenmiştir.

Model	Macro F1	AFIB F1	AFL F1	Neden elendi
CNN	74.17%	62.31%	50.20%	Sınırlı zamansal modelleme yeteneği, bu da daha zayıf ritim sınıflandırmasına yol açar.
CNN + BiLSTM	81.54%	70.48%	61.18%	Benzer performans, ancak tekrarlayan hesaplamalar eğitim karmaşıklığını artırdı ve paralel verimliliği düşürdü
CNN + TCN + Transformer	81.63%	71.34%	60.32%	Ek parametreler ve hesaplama maliyeti
Dual Branch Lead II + V1	81.38%	71.47%	61.54%	Benzer bir performans sergilese de, ilave dal, mimari karmaşıklığı artırmış, ancak anlamlı bir bir iyileştirme sağlamadı
CNN + TCN + Attention	81.25%	70.85%	60.47%	Attention modülü, standart CNN-TCN ile karşılaştırıldığında ölçülebilir bir iyileşme sağlamadı.

Tablo 6. *Değerlendirilen Model Mimarilerinin Karşılaştırması*

Bu deneylere dayanarak, zamansal havuzlama özelliğine sahip CNN-TCN mimarisi nihai model olarak seçildi. Bazı alternatif mimariler biraz daha yüksek doğrulama puanları elde etse de, bu iyileştirmeler asgari düzeydeydi ve daha fazla karmaşıklık veya hesaplama

maliyeti ile birlikte geliyordu. Nihai model, sınıflandırma performansı, verimlilik ve mimari basitlik arasında en iyi dengeyi sağladı.

5.3. Parametre Seçimi ve Deneysel Ayarlar

Hiperparametreler, doğrulama performansına göre seçildi.
Ana eğitim yapılandırması şöyleydi:

Parameter	Value
Input length	5000 samples
Number of leads	12
Batch size	32
Learning rate	1e-4
Optimizer	AdanW
Epoch limit	100
Early stopping patience	10
Loss function	Cross Entropy

Tablo 7. *Model Training Parametreleri Veri*

kümesi dengeli olduğu için sınıf ağırlıklandırması uygulanmadı. Aşırı uyumlanmayı önlemek için çeşitli düzenleme yöntemleri kullanıldı:

- Genlik ölçeklendirme, Gauss gürültüsü, zaman kaydırma, öncül bırakma, temel çizgi kayması ve zaman maskeleme dahil veri artırma.
- Doğrulama Makro F1 puanına dayalı erken durdurma.
- Sınıflandırıcı başlığı içindeki dropout katmanları.

Hiperparametre seçiminin ve performans tahmininin sağlamlığını artırmak için, tabakalı k-katlı çapraz doğrulama kullanılarak model seçimi gerçekleştirilmiştir.

5.4. Öğrenme Süreci ve Teknik Evrim

Geliştirme süreci, önceki modellerde gözlemlenen sınırlamalara dayalı olarak yapılan birkaç yinelemeli iyileştirmeden oluşmuştur. İlk yaklaşımda, EKG temsillerini doğrudan giriş sinyallerinden öğrenmek için CNN tabanlı bir mimari kullanılmıştır. Bu model, yerel dalga formu özelliklerini çıkarabilse de, birden fazla kalp atışı boyunca uzun menzilli zamansal ilişkileri yakalama yeteneği sınırlıydı. Bu nedenle, zamansal alıcı alanı genişletmek ve ritimle ilgili özellik öğrenimini iyileştirmek amacıyla bir Zamansal Evrişimli Ağ (TCN) bileşeni eklenmiştir.

Ardından, tekrarlayan modeller, Transformer tabanlı yaklaşımlar ve ek dikkat mekanizmaları dahil olmak üzere çeşitli alternatif mimariler incelenmiştir. Bu deneyler, mimari karmaşıklığın artırılmasının sınıflandırma performansını tutarlı bir şekilde iyileştirmediğini göstermiştir. Özellikle, ek bileşenlere sahip modeller, önemli bir performans artışı sağlamadan daha yüksek hesaplama maliyetlerine yol açmıştır.

Farklı girdi stratejilerini ve eğitim yaklaşımlarını değerlendirmek için ek deneyler de gerçekleştirildi. Örneğin, harici veri kümesinin [7] genişletilmesi incelendi, ancak veri dağılımındaki farklılıklar beklenen faydayı azalttı. Bu nedenle, nihai geliştirme aşaması, resmi yarışma veri kümesini kullanarak temsil öğrenmesini iyileştirmeye odaklandı.

5.5. Hesaplama Kaynakları ve Çalıştırılabilirlik

Model, aşağıdakiler kullanılarak eğitilmiştir:

Component	Özellik
GPU	NVIDIA Tesla T4 16 GB
RAM	32 GB
Framework	PyTorch
Python version	3.14.5

Table 8. *Cihaz özellikleri*

Her bir katın eğitimi ortalama olarak yaklaşık 12 dakika sürerken, bir EKG kaydı için çıkarım işlemi ortalama olarak yaklaşık 0,714 milisaniye sürdü.

Nihai model yaklaşık 591.910 parametre içermektedir ve bu da gerçekçi EKG analiz senaryolarında pratik bir şekilde kullanılmasını sağlamaktadır. Derin öğrenme modelleri, geleneksel özellik tabanlı yaklaşımlara göre daha fazla hesaplama kaynağı gerektirse de, sabit giriş uzunluğu ve verimli evrişimli tasarım, eğitimden sonra hızlı çıkarım yapılmasını sağlamaktadır.

Önerilen sistem, sınıflandırma performansı, hesaplama verimliliği ve otomatik EKG taraması için uygulanabilirlik arasında bir denge sağlamaktadır.

TEKNOFEST
İSTANBUL HAVACILIK, UZAY VE TEKNOLOJİ FESTİVALİ

REFERANSLAR

[1] J. Cai, W. Sun, J. Guan ve I. You, «Multi-ECGNet For ECG Arrythmia Multi-Label Classification,» *Preparation of Papers for IEEE Access,* cilt 4, pp. 1-11, 2020.

[2] J. Chen, T. Chen, B. Xiao, X. Bi, Y. Wang, H. Duan, W. Li, J. Zhang ve X. Ma, «SE-ECGNet: Multi-scale SE-Net for Multi-lead ECG Data,» *Computing in Cardiology,* cilt 47, pp. 1-4, 2020.

[3] Q. Yao, R. Wang, X. Fan, J. Liu ve Y. Li, «Multi-class Arrhythmia detection from 12-lead varied-length ECG using Attention-based Time-Incremental Convolutional Neural Network,» *Information Fusion,* cilt 53, pp. 174-182, 2020.

[4] S. Yaser, M. Chowdhury ve R. Sarmun, «SER Inspired Deep Learning Approach to Detect Cardiac Arrhythmias in Electrocardiogram Signals Using Temporal Convolutional Network and Graph Neural Network,» *Computers in Biology and Medicine,* cilt 195, pp. 1-10, 2025.

[5] R. Li, D. Su, S. Shen, S. Lu, Q. Zhang ve S. Zhang, «MVFF-SAT: A classification model for ECG signals integrating multi perspective features,» *Measurement,* cilt 256, no. 118149, 2025.

[6] S. Bai, J. Z. Kolter ve V. Koltun, «An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling,» 2018.

[7] J. Zheng, H. Guo ve H. Chu, «A 12-Lead Electrocardiogram Database for Arrhythmia Research Covering More Than 10,000 Patients,» *Scientific Data,* cilt 7, no. 1, p. 48, 2020.

[8] C. K. Roopa ve B. S. Harish, «A New way of classifying Cardiac conduction using CNN and Neuromorphic Model,» *Department of Information Science & Engineering,* pp. 1-4, 2019.

TEKNOFEST İSTANBUL HAVACILIK, UZAY VE TEKNOLOJİ FESTİVALİ